

幅より深さ: 安いモデル + 敵対的レビュー

0.66× のコストで、プレミアムモデルと同等品質に到達

安いモデル(qwen3-235b)に多角的な敵対的レビューループを適用し、GPT-5.1の一回回答と比較しました。

勝利

自分自身の一発回答比

+85%

95% CI +73...+96% ・ 成績 42勝-5引-1敗

勝利

単純なself-review比

+74%

95% CI +60...+88% ・ 成績 37勝-10引-1敗

引き分け

プレミアムモデル(GPT-5.1)比

+12%

95% CI -4...+27%(0をまたぐ実質的な引き分け) ・ 成績 11勝-32引-5敗

ネット勝率 = (勝ち - 負け) / タスク数。難タスク48件、ブラインド・順序入替の3モデル判定パネルによる。

主張していること・いないこと

1つの安いモデルに敵対的レビューを適用すれば、難しいタスクで約66%のコストでプレミアムモデルと同等の品質に到達し、単純な一回回答・セルフレビューを圧倒する。**しかし「プレミアムに勝つ」とは主張していない(プレミアム比のCIは0をまたぐ) — 複数モデルのアンサンブルが効くとも主張していない(別途検証で効かないことが判明) — これが簡単なタスクや、今後の全モデル世代でも成立するともいえない(簡単タスクでは差を示す余地がない)。**

手法・全ラウンドの記録・生データ: docs/EXPERIMENT_RESULTS.md、docs/PUBLICATION.md — github.com/Kota-Ohno/frugal-fusion